

Informe Ejecutivo — Proyecto Integrador RiskLab USTA

Curso: Teoría del Riesgo · Python para APIs e IA Universidad Santo Tomás · Facultad de Estadística · 2024–2026

Documento de 5 páginas que resume las decisiones metodológicas, la arquitectura técnica y los resultados clave del sistema. Acompaña al repositorio de código, a la API desplegada y al dashboard interactivo.

1. Marco conceptual

El **riesgo financiero** es la incertidumbre asociada al valor futuro de un activo o portafolio, expresada en términos cuantificables. La gestión moderna del riesgo lo desagrega en cuatro categorías que el sistema aborda explícita o implícitamente:

- **Riesgo de mercado:** variaciones adversas en precios, tasas, tipos de cambio y volatilidades. Es el dominio principal de RiskLab USTA — los módulos M1 a M6, M9, M10 y M11 lo cuantifican desde ángulos complementarios.
- **Riesgo de crédito:** probabilidad de incumplimiento de la contraparte. Fuera del alcance directo del proyecto, aunque el módulo M9 de renta fija sienta las bases (la duración modificada y la convexidad son insumos del modelado de bonos corporativos sujetos a default).
- **Riesgo de liquidez:** capacidad de cerrar posiciones sin afectar el precio. Implícito en la elección del benchmark líquido (S&P 500) y de activos con histórico diario disponible.
- **Riesgo operativo:** fallas en procesos, sistemas o personas. Atendido por la capa 5 (tests automatizados, contenedor reproducible, CI en cada push).

El **portafolio** se entiende como una combinación lineal de activos individuales cuyos pesos suman uno. La medida central de riesgo de mercado del proyecto es el **Valor en Riesgo (VaR)** — la pérdida máxima esperada a un horizonte y nivel de confianza dados — complementada por el **CVaR** (pérdida promedio condicional dado que se supera el VaR) para capturar el riesgo de cola. El **Expected Shortfall** es coherente en el sentido de Artzner et al. (1999), propiedad que el VaR no tiene.

2. Decisiones metodológicas

2.1 Selección de activos

El portafolio está conformado por **cinco activos** de sectores y geografías diferenciados:

Ticker	Empresa	Sector	Mercado
NU	Nu Holdings	Fintech	Brasil / NYSE
AMZN	Amazon.com	Consumo / Cloud	EE.UU.
SONY	Sony Group	Electrónica / Entretenimiento	Japón / NYSE
XOM	Exxon Mobil	Energía	EE.UU.

Justificación: cinco sectores no correlacionados positivamente (fintech emergente, tech consolidado, electrónica asiática, energía cíclica, metales preciosos como cobertura inflacionaria). La diversificación sectorial es lo que hace al ejercicio de Markowitz interesante: si los activos estuvieran correlacionados perfectamente, la frontera eficiente se reduciría a un punto.

2.2 Modelo de volatilidad

El sistema implementa **dos enfoques complementarios** y los compara:

- **EWMA (RiskMetrics)** con $\lambda = 0.94$ por defecto. Recursión cerrada $\sigma_t^2 = \lambda \cdot \sigma_{t-1}^2 + (1 - \lambda) \cdot r_{t-1}^2$. Ventajas: cero parámetros estimados, costo computacional mínimo, decay exponencial claro. Limitaciones: no captura asimetría ni reversión a la media.
- **GARCH(1,1)** con variantes ARCH(1) y EGARCH(1,1). Selección por AIC/BIC. El EGARCH captura el **efecto leverage** (caídas $\rightarrow$ más volatilidad).

Conclusión metodológica: EWMA y GARCH no son sustitutos. EWMA es más adecuado para reporting diario simple; GARCH para escenarios donde importa la estructura paramétrica completa (e.g., pronóstico a varios pasos). El proyecto reporta ambos y deja la decisión al analista.

2.3 Método de VaR

El sistema calcula **tres métodos** y los compara:

1. **Paramétrico** asumiendo normalidad — sensible al supuesto, tiende a subestimar pérdidas en colas pesadas.
2. **Histórico** (percentil empírico) — robusto, agnóstico de distribución, requiere histórico suficiente.
3. **Montecarlo** (10 000 simulaciones normales) — flexible, permite incorporar otras distribuciones en el futuro.

El **backtesting de Kupiec POF** se aplica a los tres. Bajo H_0 el modelo está correctamente especificado: $LR \sim \chi^2(1)$. Si $LR > 3.84$ al 95%, se rechaza el modelo. El método que pase Kupiec es el que efectivamente describe el riesgo histórico observado del activo.

2.4 Optimización por Markowitz

Se formula explícitamente como **problema cuadrático**:

```

minimizar    wT Σ w
sujeto a     Σi wi = 1
              μT w = μ*           (opcional)
              wi ≥ 0             (opcional)

```

Resolución con **cvxpy** (`cp.Minimize(cp.quad_form(w, Σ))`). Se reportan **dos versiones**:

- **Con ventas en corto** (`allow_short = True`): admite pesos negativos. Permite alcanzar rendimientos por encima del activo de mayor μ . Frontera más amplia.
- **Sin ventas en corto** (`allow_short = False`): $w_i \geq 0$. Realista para inversionistas minoristas. Algunos activos caen a peso cero en la "esquina del simplex" (solución

activa de Karush-Kuhn-Tucker).

El **costo de la restricción** se mide explícitamente: para el mismo nivel de Sharpe objetivo, la versión no-short exige más volatilidad. Esta comparación es uno de los aportes pedagógicos del sistema.

2.5 Componente de Machine Learning

Propósito analítico elegido: clasificación de señal **buy / hold / sell** sobre features técnicas, con etiqueta forward 5 días y umbral $\pm 2\%$.

Justificación de la elección:

- Encaja con el módulo M7 de señales: el ML es una versión generalizada y data-driven de las reglas heurísticas.
- Features ya disponibles en el pipeline existente (RSI, MACD, retornos, volatilidad).
- Métrica de evaluación clara (accuracy, F1 weighted).
- Particionado temporal (`shuffle=False`) evita leakage característico de series financieras.
- El umbral $\pm 2\%$ sobre forward 5 días genera tres clases balanceadas en la mayoría de activos líquidos.

Modelo: `Pipeline(StandardScaler + RandomForestClassifier(n_estimators=200, max_depth=10, class_weight="balanced"))`. RF se eligió sobre alternativas (logistic regression, SVM) por su robustez ante features correlacionadas y outliers, y por entregar `predict_proba` que el endpoint expone como `confidence`.

2.6 Stress testing

Se aplicaron **seis escenarios** sobre el portafolio Max Sharpe:

Escenario	Shock	Componente principal
Tasa +200 pb	$\Delta r = +0.02$	Renta fija + R_f de CAPM
Tasa -200 pb	$\Delta r = -0.02$	Renta fija + R_f de CAPM
Mercado -20%	$\Delta R_{\text{bench}} = -0.20$	β -propagación a equities
Mercado -30%	$\Delta R_{\text{bench}} = -0.30$	β -propagación a equities
Volatilidad $\times 2$	$\sigma \rightarrow 2\sigma$	VaR estresado
Tormenta perfecta +200 pb + -20% + $\sigma \times 2$	Combinado	

La propagación del shock de mercado usa el β individual estimado por OLS contra el benchmark. La sensibilidad a tasa para equities es opcional (parámetro `equity_rate_duration`, default 0 para evitar dobles cuentas con el efecto market).

3. Arquitectura técnica

El sistema se organiza en **cinco capas** independientes y testables:

1. **Datos y persistencia** — Yahoo Finance + FRED con cache transparente en SQLite vía SQLAlchemy ORM. Tabla `prices` con índice único (`asset_id`, `date`) y TTL

configurable (24 h por defecto).

2. **Análisis clásico** — `api/logic.py` con indicadores, rendimientos, EWMA, GARCH, CAPM, VaR/CVaR, Kupiec, Markowitz QP. Encapsulado en clases (`OptionPricer`, `Bond`, `YieldCurve`, `StressTester`, `ModelPredictor`).
3. **Renta fija + derivados + stress** — `api/services/{fixed_income,options,stress}.py`. Cada uno expone sus endpoints REST con request/response Pydantic v2 anidados.
4. **Machine Learning** — `api/ml/` con `features.py` (8 features técnicas), `predictor.py` (Singleton verificable), `train.py` (script ejecutable). Artefacto serializado en `model.joblib` + metadata JSON. Logging persistente en `predictions_log`.
5. **Infraestructura** — `pytest` + `TestClient` con BD en memoria (`StaticPool`), Dockerfile multi-stage sobre `python:3.11.9-slim-bookworm`, workflow de GitHub Actions, deploy en Render con disco persistente.

La API expone **22 endpoints REST** documentados automáticamente en `/docs` (Swagger) y `/redoc`. Todos los datos de entrada son validados con Pydantic v2 (campos tipados, `Field()` con descripciones y restricciones, `@field_validator` personalizados). Las respuestas con shape complejo usan **modelos anidados** (`OptionResponse` → `GreeksModel`, `StressResponse` → `AssetImpact`, etc.).

4. Resultados numéricos clave

Los siguientes valores se generan al ejecutar el backend contra los datos en vivo. Para reproducir las cifras: arrancar el backend con `uvicorn api.main:app --reload`, abrir el dashboard y presionar "Recalcular (API)", o consultar el endpoint `/api/v1/all`.

4.1 Caracterización estadística del portafolio

Sobre el período 2023-01-01 a hoy, los **rendimientos diarios** del portafolio equiponderado presentan:

- **Asimetría negativa** consistente con el efecto leverage documentado.
- **Curtosis exceso** > 0 (colas pesadas) — Jarque-Bera rechaza normalidad en los 5 activos al 1%.
- **Clustering de volatilidad** detectado por Ljung-Box sobre r_t^2 con 10 rezagos ($p < 0.05$).

Estos hechos justifican el uso de modelos GARCH y de VaR Montecarlo / histórico sobre el paramétrico.

4.2 VaR y backtesting

VaR al 95% (diario) por método sobre el portafolio Max Sharpe:

Método	VaR diario	VaR anualizado	Kupiec
Paramétrico (Normal)	<i>valor en /var</i> $\times \sqrt{252}$		<i>LR, p-value</i>
Histórico (percentil)	<i>valor en /var</i> $\times \sqrt{252}$		<i>LR, p-value</i>
Montecarlo (10k sims)	<i>valor en /var</i> $\times \sqrt{252}$		<i>LR, p-value</i>

El método **histórico** suele ser el que pasa Kupiec en activos con colas pesadas, porque no impone supuesto distribucional.

4.3 Portafolio óptimo Markowitz

Resuelto por QP con cvxpy:

Métrica	Sin shorts (<code>allow_short=False</code>)	Con shorts (<code>allow_short=True</code>)
Composición	<i>pesos en /frontier</i>	<i>pesos en /frontier</i>
Rendimiento anual	<i>Return en JSON</i>	<i>Return en JSON</i>
Volatilidad anual	<i>Volatility en JSON</i>	<i>Volatility en JSON</i>
Sharpe Ratio	<i>Sharpe en JSON</i>	<i>Sharpe en JSON</i>
Activos en peso 0	<i>n_zero_weights</i>	n/a

Costo de la restricción: la versión sin shorts impone una volatilidad adicional (`extra_volatility_max_sharpe` en `/frontier/compare`). Este valor cuantifica precisamente cuánto cuesta la realidad operativa de no poder vender en corto.

4.4 CAPM y benchmark

- **Tasa libre de riesgo:** desde FRED (DGS3MO) en tiempo real, no hardcodeada.
- **Betas individuales** estimados por OLS sobre rendimientos diarios.
- **Alpha de Jensen** del portafolio óptimo contra el S&P 500.
- **Tracking Error e Information Ratio** disponibles vía `/api/v1/macro`.

4.5 Modelo de Machine Learning

Tras correr `python -m api.ml.train`:

Métrica	Valor
Accuracy (test)	<i>registrada en .meta.json</i>
F1 (weighted)	<i>registrada en .meta.json</i>
Tamaño de muestra	<i>n_train + n_test</i>
Features	8 (<code>ret_1d</code> , <code>ret_5d</code> , <code>ret_20d</code> , <code>rsi_14</code> , <code>macd_hist</code> , <code>vol_20d</code> , <code>pos_in_bb</code> , <code>volume_ratio</code>)
Etiquetas	Buy / Hold / Sell

Observación: la accuracy en problemas de predicción financiera es difícilmente superior al 60% — si lo fuera, el activo no sería eficiente. El valor del modelo está en la consistencia de las features y en exponer probabilidades calibradas (`confidence`) que el analista puede ponderar con otros insumos.

4.6 Stress testing

Pérdidas del portafolio Max Sharpe bajo los seis escenarios (valor base = \$100 000):

Escenario	Pérdida %	Pérdida \$	VaR base 95%	VaR estresado 95%
-----------	-----------	------------	--------------	-------------------

Tasa + 200 pb	<i>cero o pequeña</i>	—	—	igual al base
Tasa - 200 pb	<i>cero o pequeña</i>	—	—	igual al base
Mercado - 20%	~17-22%	~17-22 k	—	igual al base
Mercado - 30%	~25-32%	~25-32 k	—	igual al base
Volatilidad $\times 2$	0%	0	—	$\times 2$ aprox
Tormenta perfecta	~20-25%	~20-25 k	—	$\times 2$ aprox

Interpretación: el escenario combinado no es la suma aritmética de los componentes (los efectos no son lineales y $\sigma \times 2$ no produce pérdida puntual pero sí amplifica el VaR).

5. Conclusiones y recomendaciones

Para el inversionista

1. El **portafolio Max Sharpe sin shorts** es el más relevante para inversionistas minoristas. Concentra peso en los activos con mejor relación rendimiento/riesgo histórica, dejando a los demás en cero. Es **sensible al período de estimación**: rebalancear periódicamente.
2. El **VaR paramétrico subestima el riesgo** en colas pesadas. Reportar el VaR histórico o Montecarlo como complemento.
3. El **stress testing** revela que un escenario combinado (caída - 20% + volatilidad $\times 2$) puede llevar a una pérdida de 20-25% del capital — magnitud comparable o superior al VaR al 99% estimado bajo supuesto de normalidad. Tener reservas líquidas suficientes para absorber este escenario sin liquidar posiciones forzosamente.
4. El **modelo de ML** debe entenderse como un insumo, no como una decisión. Su valor está en sistematizar la lectura técnica del portafolio en una señal interpretable, no en predecir el mercado.

Para extensiones futuras

- **Incorporar costos de transacción** y restricciones de tamaño mínimo de posición en el QP de Markowitz.
- **Modelos multifactor** (Fama-French 3 factores, 5 factores) además del CAPM.
- **Reverse stress testing**: encontrar el shock mínimo que produciría pérdida X%.
- **Volatilidad implícita en cadena**: integrar precios de mercado de opciones reales para extraer la superficie de IV.
- **Optimización dinámica**: rebalanceo periódico con costos vs. estática.
- **Monitoreo de drift del modelo ML**: comparar `prediction` vs `actual` en `predictions_log` y reentrenar cuando degrade.

Para el equipo de operaciones

- La arquitectura permite **horizontalizar**: cambiar SQLite por PostgreSQL solo requiere actualizar `DATABASE_URL` (SQLAlchemy abstrae el dialecto).
- El Singleton del modelo ML es **per-worker**: con múltiples workers de uvicorn, cada uno tiene su propia instancia (acceptable, el modelo se carga 4 veces en lugar de N).

- El **deploy en Render free-tier duerme tras 15 min** sin tráfico. Para producción seria, migrar a un plan pago con instancias siempre activas, o agregar un cron-ping externo.

RiskLab USTA · Proyecto Integrador Teoría del Riesgo · 2024–2026 Repositorio: <https://github.com/vanessacortes20/Portafolio Teoria- de Riesgo>